# "Written All Over the Face": Driving Facial Robots via LLM Internal Emotion Manifolds

Author Name[1] and Author Name[2]

***Abstract*— 面部作为人机交互中最自然的情绪入口，其交互潜能正随着高自由度面部硬件与大语言模型表征能力的同步成熟而被加速释放。然而，要实现表情随对话快速、灵动响应并准确传递情绪信息，目前仍缺乏可靠的技术路径。现有大模型驱动方案普遍依赖句级离散情感标签，导致表情更新滞后且无法表达句内细腻的情绪转折。为此，我们提出 EmotionManifold：不令模型 "说出" 情绪，而是在流式解码中直接从模型隐状态提取连续情感表征并实时驱动面部硬件的全新架构，实现了表情与 Token 生成的高频同步。实验表明，相比传统的话轮级控制基线，该方法不仅在复杂语境下展现出精准的词级情感捕捉能力（同词跨语境效价差 $\Delta V \approx -0.22$），将表情响应延迟降低了一个数量级，更在实机面部执行时显著提升了对句内动态情绪转折的拟合精度（效价与唤醒度的 $R^2$ 分别提升 22% 与 19%），为快速、细腻且可验证的具身情感交互确立了新范式。**

## I. INTRODUCTION

在具身智能的发展蓝图中，尽管主流范式侧重于使机器人掌握操纵等实用物理技能，但大语言模型（LLM）强大的表征能力与高自由度面部硬件的同步成熟，正推动面向陪伴与交互的面部机器人（Facial Robots）成为率先落地的核心载体之一（Ahmed et al., 2024）。为实现自然灵动的人机交互，在工程层面上，语言-表情同步（Speech-Expression Synchronization）是亟待突破的重要瓶颈。

"It's written all over your face." 神经科学研究表明，人类在进行语言表述时，皮层下通路（Subcortical Pathways）会持续将底层情绪状态外显为面部微表情，使情感的流动与言语的表达形成紧密的同频共振（LeDoux, 1996）。面部机器人的控制工程应当借鉴这一机制启发，以达到更自然的人机交互效果：即情绪信号应当直接从模型实时的内部认知流中提取，并流式驱动表情更新。然而，当前主流方案——无论是早期的显式规则切换，还是近期基于 LLM 的结构化输出与非言语行为调度——普遍令模型在生成对话内容的同时附带离散情绪标签，再据此映射预设表情；标签虽可与回复一并产生，其语义单元仍停在话轮（Turn）尺度。相比之下，语言生成是以 Token 为基本单元自回归流式推进的，其内部往往交织着高频的句内（Intra-utterance）情感转折。这种时序粒度错配不可避免地导致了面部执行相对于语言内容轨迹的错位，并在整句尺度上粗暴地抹平了本应精细可辨的动态情感轨迹。

为了解决上述瓶颈，本文提出了 EmotionManifold：一种在流式解码过程中直接从大模型隐状态（Hidden States）中读回连续情感坐标，并实时外显为面部微表情的全新架构。在表征机制上，该方案摒弃了依赖外部离散标签的传统做法，建立了一条"隐状态 → 连续 VAD 轨迹 → 物理面部"的直通管线：在每个 Token 发射的瞬间，瞬时隐状态被直接投影至 VAD 情感子空间，该连续信号随即被平滑映射，用以驱动 29 自由度的面部硬件系统。该架构无需繁重的参数微调或外部情感 API，仅依赖原生前向传播即可高效运行。通过这种极简管线，物理执行与认知 Token 发射共享同一时钟，真正实现了"情动于内、形于外"的效果。

本文的主要贡献如下：

- **提出一条免训练、可实时运行的表情驱动极简管线**：在模型解嵌入矩阵上离线构造三条 VAD 情感轴并张成情感子空间，于流式解码过程中对隐状态做投影（词级读回精度 Spearman $\rho_V = 0.837$），再经轻量级网络与预置表情映射至高自由度面部执行器；无需参数微调或外部情感接口，实机工控机上逐 Token 附加开销仅 0.7 ms，极为便于本地部署。
- **实现与语言生成严格同步的细粒度表情控制**：与以话轮为单位输出离散情绪标签的现有做法不同，本方法在每个生成 Token 上更新连续情感坐标；同词跨语境对照表明，正面关键词在复杂情感（如讽刺）条件下的 Token 级效价显著下降（$\Delta V \approx -0.22$），说明驱动信号能够敏锐捕捉句内语用转折，而非简单的表面词汇查表。
- **从认知表征到物理实机完成了闭环的客观与人因验证**：在公开词典与讽刺压力测试上检验了读回一致性与语境敏感性；在 29 自由度实机上以四条件同场对照、经视觉回读评估了执行保真度（句内效价转折

[1]Affiliation TBD. email@domain.edu
[2]Affiliation TBD. email@domain.edu

方向命中率达 87.5%，而话轮级与乱序基线均仅在机会水平）；并用人因问卷确认了表情可辨识，且受试者对句内动态表情的偏好显著高于话轮级与乱序对照。

论文后续结构安排如下：第二节回顾相关研究工作；第三节详细阐述本文提出的核心方法；第四节汇报实验设计与系统评估结果；第五节讨论当前系统的局限性并给出最终结论。

## II. RELATED WORK

机器人面部表情生成的研究可追溯至基于面部运动编码系统（FACS）的动作单元（Action Unit）描述传统（Ekman & Friesen, 1978），以及早期交互系统（如 Kismet）在二维情感空间（Affect Space）中实现连续动态表情过渡的开创性实践（Breazeal, 2003）。近年来，高度仿真的面部硬件平台（如 Emo，Hu et al., 2024）以及面向 Ameca 机器人的 X2C 数据集（Li et al., 2025）极大提升了机械面部的连续形变能力。然而与之形成反差的是，在控制层面，实现与流式言语（Unfolding Speech）高频同步的自动化自适应表情管线仍是人机交互（HRI）领域的突出瓶颈。随着大语言模型（LLM）的普及，业界已迅速转向由 LLM 驱动的新范式（如 FurChat、SAFE、Nadine 及 Expressive Furhat 等）。其中，当前主流路线普遍以外部离散标签驱动面部：例如 Mishra 等（2023）为即将发出的话轮预测离散情绪，Xpress（Antony et al., 2025）则由模型输出情绪类别与强度。二者构成了本文实验的主要对照系统。

然而，语言生成是以 Token 为基本单元自回归推进的。面对句内否定、转折与讽刺等复杂语用变化，上述依赖整句或话轮离散标签的“外挂式”方案，在结构上无法刻画 Token 级的连续情感漂移。相比离散类别，效价-唤醒度-支配度（VAD）连续情感空间（Russell & Mehrabian, 1977; Mohammad, 2018）为细粒度表情驱动提供了更理想的中间表示；同时，机制可解释性（Mechanistic Interpretability）研究亦证实，LLM 隐空间中天然存在可线性读出的情感结构与低维情感流形（Tigges et al., 2024; Reichman et al., 2026）。基于这一共识，本文彻底摒弃将表情编码为离散符号字段的传统做法，改为在解码过程中直接从隐状态读回连续 VAD 轨迹，并以 Token 时钟驱动面部执行，从而在认知表征与具身表情之间建立起真正的同频通道。

## III. METHOD

图 1概述了 EmotionManifold 的整体架构。我们将“从语言内部表征到物理表情”这一端到端映射解耦为三个可独立标定的阶段：(A) 情感轴挖掘与子空间标定；(B) 逐 token 流式投影；(C) 表情映射与物理执行。其中阶段 A 为一次性离线过程，阶段 B 与 C 在运行期以内置的前向传播开销实时完成，全程无需参数微调，也无需额外的情感分类接口。具体细节如下所述：

### A. 情感轴挖掘与子空间标定

本阶段的目标是在不引入任何训练的前提下，于 LLM 隐空间中显式构造出与心理学 VAD 模型（Russell & Mehrabian, 1977）对齐的三条情感轴，并由其张成三维 VAD 情感子空间。设 $\mathbf{W}_{\text{out}} \in \mathbb{R}^{|\mathcal{V}|\times d}$ 为模型的解嵌入（unembedding）矩阵，其中 $|\mathcal{V}|$ 为词表大小、$d$ 为隐层维度。我们从 NRC-VAD 词典（Mohammad, 2018）中为每一维度选取得分最高与最低的各 $N$ 个词，构成正负极词簇（pole word clusters）$\mathcal{C}_k^+$ 与 $\mathcal{C}_k^-$，$k \in \{V, A, D\}$。对给定极性（$* \in \{+, -\}$）的词簇 $\mathcal{C}_k^*$，计算其在解嵌入矩阵中对应行向量的平均嵌入：

$$\bar{\mathbf{e}}_{\mathcal{C}_k^*} = \frac{1}{|\mathcal{C}_k^*|} \sum_{w \in \mathcal{C}_k^*} \mathbf{W}_{\text{out}}[\text{id}(w), :], \tag{1}$$

其中 $\text{id}(w)$ 为词 $w$ 首个内容 token 的索引。第 $k$ 维情感轴定义为两极词簇质心的归一化差向量：

$$\mathbf{v}_k = \frac{\bar{\mathbf{e}}_{\mathcal{C}_k^+} - \bar{\mathbf{e}}_{\mathcal{C}_k^-}}{\left\|\bar{\mathbf{e}}_{\mathcal{C}_k^+} - \bar{\mathbf{e}}_{\mathcal{C}_k^-}\right\|_2}. \tag{2}$$

三条情感轴 $\{\mathbf{v}_V, \mathbf{v}_A, \mathbf{v}_D\}$ 共同张成 VAD 情感子空间；后文在讨论逐维投影与构轴过程时称“情感轴”，在讨论轨迹几何、正交性与表情映射时称“情感子空间”。极词数 $N$ 在轴的稳定性与语义特异性之间权衡：$N$ 过小则轴易受个别词的特异性干扰，过大则混入弱情感词而稀释方向。我们在实验部分对 $N \in [10, 80]$ 进行扫描（第 IV-A 节），并采用 $N = 50$ 作为默认配置。由于原始投影值的数值范围依模型与维度而异，我们另以少量含词典词的句子做一次性离线最小二乘拟合，得到逐维仿射参数 $(s_k, b_k)$，将投影值对齐至词典语义尺度 $[-1, 1]$（AdaptiveScaler）；推理时该参数固定。整个阶段是模型特定的——每个 backbone 需独立重算三条情感轴——但完全免训练：仅需词典筛选与对 $\mathbf{W}_{\text{out}}$ 的一次只读访问，在消费级硬件上数秒内即可完成。

### B. 逐 Token 流式投影

运行期，模型以因果解码逐 token 生成回复。在第 $t$ 步，设 $\mathbf{h}_t \in \mathbb{R}^d$ 为末层最后位置的隐状态，即刚发射 token 的上下文表示。我们对其做 L2 归一化以消除隐状态范数随位置的漂移，再沿三条情感轴投影至 VAD 情感

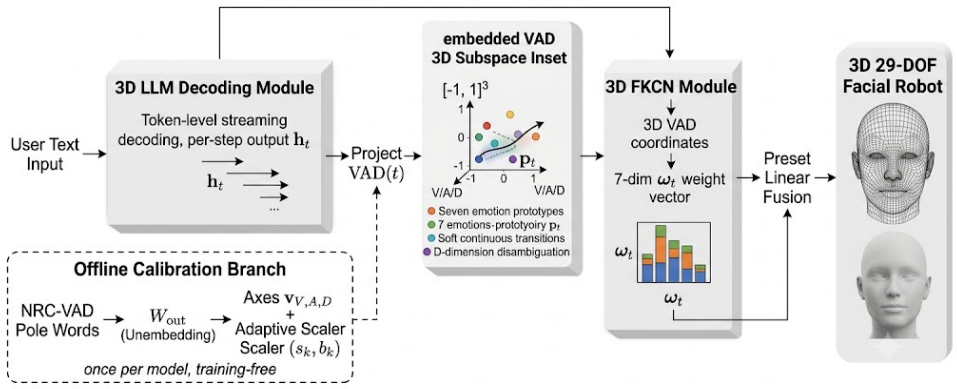



Fig. 1 Unified System Framework with FKCN VAD Subspace Inset

Fig. 1. EmotionManifold 系统总览。在线通路（上）：用户文本经 LLM 逐 token 流式解码，每步隐状态 $\mathbf{h}_t$ 投影为 VAD($t$)，经 FKCN 得到七维表情权重 $\boldsymbol{\omega}_t$，再经 preset 线性融合驱动 29 自由度面部。中央内嵌图为 VAD 情感子空间示意（原型、轨迹 $\mathbf{p}_t$ 与软连续过渡）。离线标定支路（下，虚线框）：NRC-VAD 极词与解嵌入矩阵 $\mathbf{W}_{\text{out}}$ 构造三条情感轴 $\mathbf{v}_{V,A,D}$ 及 Adaptive Scaler $(s_k, b_k)$，一次性完成、免训练。

子空间并施加标定：

$$\hat{\mathbf{h}}_t = \frac{\mathbf{h}_t}{\|\mathbf{h}_t\|_2}, \qquad \tilde{z}_{t,k} = \mathrm{clip}\big(s_k\, \mathbf{v}_k^{\top} \hat{\mathbf{h}}_t + b_k,\, -1,\, 1\big), \quad k \in \{V, A, D\}. \tag{3}$$

由此得到与 token 发射严格同步的连续情感轨迹 $\{\tilde{\mathbf{z}}_t\}$。区别于将离散情感标签作为结构化输出字段、以话轮为语义单元的调度方案（Mishra et al., 2023），该读回在每个解码步即时可用，天然具备句内时间分辨率——这正是捕捉否定、转折与讽刺等句内情感漂移的结构性前提。由于隐状态在标准前向传播中本已计算，投影仅引入三次 $d$ 维点积，实机工控机上的逐 token 附加开销实测 0.7 ms（第 IV-C节）；整条链路在本地 CPU 上即可维持实时。面向离线评测，需要句级坐标时采用末内容 token 聚合或长度加权平均；token 级分析（如讽刺触发词的跨语境对照）则直接保留关键词位置的 $\tilde{z}_{t,V}$。在线执行所用的平滑与插值属于硬件通路后处理，见第 III-C节；评测一律使用原始读回轨迹。

### *C. 表情映射与执行*

**子空间连续映射。**直接在 VAD 情感子空间中逐自由度标定机器人面部代价高昂且不可迁移；相比之下，基本表情空间为面部硬件提供了自然的标定基。为此我们采用模糊 Kohonen 聚类网络（FKCN）（Han et al., 2013），将该子空间中的点连续映射为七种基本表情（中性、快乐、惊讶、恐惧、悲伤、厌恶、愤怒）的融合权重 $\boldsymbol{\omega}_t \in \Delta^6$（非负且和为一）。

FKCN 由 $P = 13$ 个模糊原型 $\{(\mathbf{c}_j, \mathbf{w}_j)\}_{j=1}^{P}$ 构成，其中 $\mathbf{c}_j \in \mathbb{R}^3$ 为原型在情感子空间中的坐标，$\mathbf{w}_j$ 为该原型所属基本表情的 one-hot 向量；原型坐标在环状情感模型（circumplex model）（Russell, 1980）所给出的效价–唤醒度区位基础上，进一步沿支配度维扩展锚定，使七种基本情绪在完整 VAD 情感子空间中各据典型区域。给定输入 $\mathbf{p}_t = (\tilde{z}_{t,V}, \tilde{z}_{t,A}, \tilde{z}_{t,D})$，计算其到各原型的平方距离 $d_{tj} = \|\mathbf{p}_t - \mathbf{c}_j\|^2$，并由反距离归一化得到模糊隶属度 $\mu_{tj} = \big(d_{tj} \sum_{l=1}^{P} d_{tl}^{-1}\big)^{-1}$（与原型重合时退化为硬指派）。输出权重为隶属度对原型标签的加权和：

$$\boldsymbol{\omega}_t = \sum_{j=1}^{P} \mu_{tj}\, \mathbf{w}_j. \tag{4}$$

与最近邻式的硬分类不同，该映射在整个 VAD 情感子空间中连续：位于原型之间的坐标产生多种基本表情的软混合而非离散跳变，延续了 Kismet 以来“情感状态是连续空间中一个移动的点”的表达传统（Breazeal, 2003）。

**硬件执行与信号调优。**执行层将七维权重融合为舵机指令。每种基本表情对应一个离线标定的预置向量（preset）$\mathbf{p}^{(m)} \in [0,1]^{29}$：标定时逐关节调节物理面部至该表情的目标位形，并按各通道行程上下限将关节角归一化为无量纲因子（factor）。运行期，29 维目标因子由 FKCN 权重对预置向量线性融合得到：

$$\mathbf{f}_t = \sum_{m=1}^{7} \omega_{t,m}\, \mathbf{p}^{(m)}, \qquad \mathbf{f}_t \leftarrow \mathrm{clip}(\mathbf{f}_t,\, 0,\, 1), \tag{5}$$

再经逐通道行程映射转换为舵机角度，通过串口下发。为在离散 token 事件与固定节拍的硬件刷新之间桥接，并对送入下游的信号流抑制逐 token 抖动，我们先施加指数滑动平均（EMA，$\alpha = 0.6$），再以 10 fps 对相邻表情目标做缓入缓出（smoothstep）插值，并施加单帧变化上限（每因子每帧至多 0.05）；单次运动窗口与帧周期对齐（100 ms），以匹配舵机物理响应极限。上述平滑仅作用于硬件显示通路。

值得强调的是，上述融合在预置表情权重空间中进行，与具体舵机运动学解耦。若更换面部显示方式，只需为新的显示端重新设定表情映射，从隐状态到 VAD 情感子空间、再到 FKCN 的计算不必改动。实验部分用

Grimace 仿真脸展示这一迁移；在 29 自由度实体面部机器人上完成执行保真度等定量评估。该设定与依赖平台特定逆模型学习的方案（Chen et al., 2021; Hu et al., 2024）不同。

## IV. EXPERIMENTS

实验回答三个层层递进的问题：（A）由情感轴张成的 VAD 情感子空间，其逐维读回是否与人工标注一致、几何结构是否可靠？（B）在句子语境中，投影读出的情感是否反映说话人的真实意图，而不是简单复读表面词汇？（C）该情感信号经映射与执行后，能否在实机面部上保真呈现？除特别说明外，实验模型默认为 Qwen2.5-0.5B，情感轴与标定参数按第 III-A节所述、以每极 50 个英文极词离线构建；所有评测只做前向传播，不涉及任何参数更新。

### A. 情感子空间可靠性

如果一条情感轴是可靠的，那么把任意情感词的嵌入向量投影到这条轴上，得到的分值排序应当与人工标注的效价排序一致。具体地，从 NRC-VAD 词典（Mohammad, 2018）中另取 300 个未参与构轴筛选的评测词（每个维度 100 词，按该词在 NRC 标注中最突出的维度归组），将每个词在解嵌入矩阵中的行向量归一化后与对应轴做点积、经仿射标定，得到模型分值，再与 NRC 人工分值计算 Spearman 秩相关 $\rho$。为了让不同模型在完全相同的词表上评测、结果可直接比较，评测词均筛选为在全部五个对照模型（2B–8B 的五个开源 LLM）的分词器中都恰好编码为单个 token 的词——多 token 词在解嵌入矩阵中没有唯一的行向量，无法跨模型公平对比。

轴的质量取决于每极选多少个极词（$N$）。图 2展示了 $N$ 从 10 到 80 变化时，六个模型（五个对照模型加本文部署的 Qwen2.5-0.5B）在同一评测词表上的 $\rho$。三个维度呈现一致的规律：$N$ 较小时轴不稳定，随 $N$ 增大相关性上升，并在 $N \approx 50$ 后饱和——六模型均值上，效价 $\rho_V$ 从 0.73 升至 0.79，唤醒度 $\rho_A$ 从 0.51 升至 0.75，支配度 $\rho_D$ 从 0.49 升至约 0.65。据此全文取 $N$=50。值得注意的是，参数量仅为对照模型 1/4 至 1/16 的 Qwen2.5-0.5B 并未掉队：$N$=50 时其 $\rho_V = 0.837$（$p < 10^{-26}$，$n$=100）位于六模型区间的上沿，$\rho_A = 0.665$、$\rho_D = 0.663$ 落在区间内偏下。改用中文极词重复整个流程（中文评测词表按同样的单 token 原则另建），得到 $\rho_V = 0.823$、$\rho_A = 0.803$、$\rho_D = 0.702$，说明该构造对构轴语言不敏感。

表 I在 $N$=50 下逐模型列出三维相关。六个模型的分值处于同一量级（三维均值 0.68–0.78），Qwen2.5-0.5B 的效价相关为六者最高。由于构轴只需要一部词典和对解嵌入矩阵的一次只读访问（第 III-A节），换用任何开源模型时整套流程原样适用；此结果进一步说明，将模型缩小到端侧可部署的 0.5B 规模并不会破坏隐空间中的情感结构。

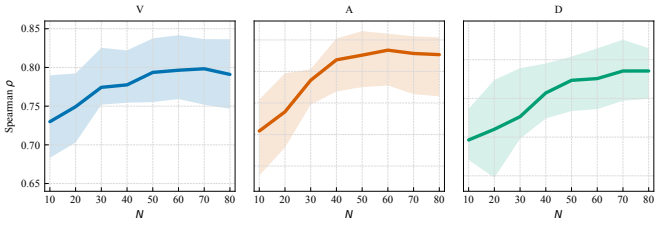



Fig. 2. 极词数 $N$ 扫描下的词级 Spearman 相关（V/A/D 三栏，英文 hold-out 300 词）。实线为六模型（五个 2–8B 基线 + Qwen2.5-0.5B）均值，阴影带为 min–max 范围。三维度均在 $N \approx 50$ 后饱和，支持以少量极词构造稳定的 VAD 情感轴。

TABLE I

跨模型词级 Spearman 相关（英文 NRC-VAD hold-out，每极 $N$=50）。前五行为 2–8B 开源基线模型，末行为本文部署模型。

| Model | $\rho_V$ | $\rho_A$ | $\rho_D$ |
|---|---|---|---|
| Gemma-2.2-2B | 0.802 | 0.650 | 0.598 |
| Llama-3.2-3B | 0.800 | 0.828 | 0.708 |
| Mistral-7B-v0.3 | 0.794 | 0.788 | 0.567 |
| Qwen2.5-7B | 0.755 | 0.792 | 0.648 |
| Llama-3.1-8B | 0.773 | 0.788 | 0.697 |
| Qwen2.5-0.5B (ours) | **0.837** | 0.665 | 0.663 |

TABLE II

VAD 情感轴正交性与跨语言情绪簇凝聚度（Qwen2.5-0.5B，$N$=50）。凝聚度为五组多语言情绪词簇的簇内平均两两余弦；括号内为随机 3 维基线（每簇 100 次）。

| Lex. | $\lvert\cos_{VA}\rvert$ | $\lvert\cos_{AD}\rvert$ | $\lvert\cos_{VD}\rvert$ | Clust. (rand.) |
|---|---|---|---|---|
| EN-only | 0.151 | 0.194 | 0.153 | 0.913 (0.410) |
| ZH-only | 0.220 | 0.116 | 0.186 | 0.898 (0.410) |

下游 FKCN 在完整的三维 VAD 情感子空间坐标上计算到各原型的欧氏距离，这隐含要求三条情感轴方向上近似互不重叠，且该子空间应编码语言无关的情感语义而非词形伪影。表 II汇总轴间正交性与五组跨语言情绪词簇凝聚度（每簇含同义异语对应词，簇内平均两两余弦；随机 3 维基线每簇重复 100 次）。

无论以英文还是中文极词构轴，任意两条情感轴的方向余弦绝对值都不超过 0.22，接近正交；跨语言簇内平均余弦分别为 0.913 与 0.898，远高于随机基线 0.410，表明该情感子空间捕获的是语言无关的情感几何。

图 3以四种基本情绪为例，直观展示英语、中文与泰语对应词在 VAD 情感子空间中的邻近分布及语境差异。

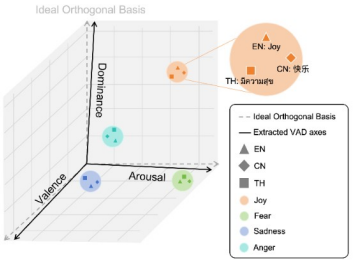



Fig. 3. 跨语言情绪词在 VAD 情感子空间中的语境敏感性示意。实线为挖掘所得三条情感轴，虚线为理想正交基；同色簇表示同一情绪（Joy、Fear、Sadness、Anger），三角/菱形/方块分别为英语、中文、泰语对应词。同义异语坐标邻近但非重合，表明读回对语言与语境敏感，而非简单词形查表。

### *B.* 语境敏感性：讽刺压力测试

词级相关只证明了投影与词典先验一致；如果读回本质上等价于查词典，它对 “lovely” 永远输出正效价，也就无法驱动跟随句内语用转折的表情。讽刺恰好是检验这一点的对抗场景：讽刺句用正面措辞传递负面意图，表面词汇与真实情感方向相反（Abu Farha et al., 2022）。

我们以 iSarcasmEval SubTask C 英文测试集为底本，它提供 200 对 “讽刺句 + 表达相同意图的非讽刺改写”。直接使用原句有两个问题：许多句子依赖特定文化背景（球队、政客、品牌），且孤立引语不含判断讽刺所需的情境。因此我们按固定协议将每对人工改写为一组语境三元组，每条由 “一句可观察的情境 + 一句引语” 构成，三个条件共享同一说话人意图：S（讽刺）在不利情境下给出正面引语，如朋友抱怨球队昨晚又输了，我说：“你们队今天打得真好！”；P（真诚正面）在有利情境下给出同一句正面引语，如朋友庆祝球队昨晚赢了，我说：“你们队今天打得真好！”；N（字面负面）在不利情境下给出负面引语，如朋友抱怨球队又输了，我说：“很遗憾你们队没赢。”。关键设计在于 S 与 P 的引语逐词相同，仅一句情境不同——任何两条件间的投影差异只能来自语境。改写时以通用日常场景替换文化专名，并为每条标注 1–3 个锚定情绪关键词（如上例中的 well）。全部 200 组三元组连同改写协议随论文发布。

三元组经与全文相同的前向管线投影。句级效价取句末 token 的标定投影值（因果注意力下，末 token 的隐状态汇聚了整句信息）；关键词级取锚定关键词所在 token 位置的投影值。可证伪的预测是：若读回由表面词汇决定，则措辞相同的 S 与 P 应得到同样的高效价；若读回整合了语境，则 S 应向意图相同的 N 靠拢。

作为参照，在不加情境的原始句上（10 对开发样本），

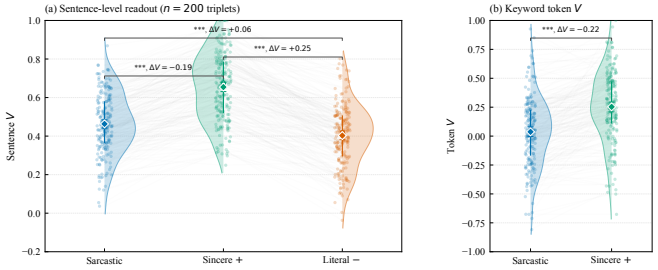



Fig. 4. 语境化讽刺压力测试（$n$=200 三元组，Qwen2.5-0.5B）。**(a)** 讽刺（S）、真诚正面（P）、字面负面（N）三条件的句级投影效价：半小提琴为核密度，箱线为四分位距，散点为逐三元组得分，菱形为 bootstrap 均值 ±95% 置信区间，灰线连接同组三元组。S 与 N 大范围重合（81.5% 满足 $|V_S - V_N| < 0.15$）。**(b)** 首要锚定正面关键词处的 token 级效价（S vs. P）：同一词在讽刺语境下均值低 0.22。

讽刺句的投影效价保持强正（$\bar{V}_S \approx 0.42$），比其字面负面改写高出约 0.41——不出所料，孤立句子中模型只能看到正面词汇。而在注入一句情境后的全部 200 组上，格局明显改变：$\bar{V}_S = 0.46$、$\bar{V}_P = 0.65$、$\bar{V}_N = 0.40$。讽刺句与字面负面句的效价差收窄至 +0.06，81.5% 的三元组中两者相差不足 0.15，即讽刺句在句级上已与 “负面意图” 基本重合；同时，引语完全相同的 S 显著低于 P（差 −0.19）。三组配对差异均通过 Wilcoxon 符号秩检验（$n$=200，均 $p < 10^{-11}$）。图 4给出三条件的完整分布及逐三元组的配对连线。

句级差异原则上仍可能由句中其他词贡献。为彻底排除词汇因素，我们把对比压缩到单个 token：同一个正面关键词（如 well），在 S 与 P 两句中位置与词形完全相同，仅前置情境不同。在每组的首要关键词上（$n$=200），讽刺语境下该词的投影效价系统性地低于真诚语境，平均差 −0.22；将统计范围扩大到所有在 S、P 中均出现的关键词（$n$=325），效应保持在 −0.20。相比之下，同一对照下唤醒度与支配度的偏移都小于 0.07——语境调制集中出现在效价维上，与讽刺 “极性反转、而非唤醒改变” 的语用学刻画一致（Leggitt & Gibbs, 2000）。由于两句在该词上没有任何词形差异，这一结果无法用词典查表解释：隐状态在该 token 处携带的，是经过上下文整合后的情感表征。

综合两级证据：给定最少一句情境，句级效价即与说话人意图对齐；控制词形后，token 级效价仍随语境改变方向。这说明送往下游表情管线的信号反映的是语用层面的情感，为第 IV-C节的实机评估提供了上游依据。

### *C.* 实机执行保真度与人因验证

前两节证明了上游信号的可靠性；本节回答链路的最后一问：逐 token 的情感指令经映射与舵机执行后，能否在物理面部上留下可回读的痕迹——以及这一能力是否

为逐 token 控制所独有。评测在同一机器人、同一机位的一场录制中比较四个条件：20 条覆盖基本情绪、EmoBank 效价/唤醒极值、GoEmotions 及句内转折类别的英文刺激句，逐条送入部署于机器人的 Qwen2.5-0.5B 流式管线现场生成回复；对同一段回复，本文管线逐 token 驱动面部（ours），Mishra 式与 Xpress 式基线用 GPT-4o-mini 对回复文本做话轮级分类后整句定脸，随机对照将 ours 的 token 级轨迹打乱时间顺序后驱动。固定机位相机录制全程，离线用面部表情 VA 回读器逐帧估计面部效价与唤醒，与逐 token 指令轨迹（EMA $\tau$=0.6 s 平滑）对齐比较。

逐帧数值重合不是合理的判据——舵机带宽与回读器精度都有限；论文主张的是句内转折被朝正确方向执行。因此以事件级二选一（2AFC）检验：当指令 VA 在 2 s 窗内摆动超过阈值（$|\Delta V| > 0.3$、$|\Delta A| > 0.2$）时，检查面部回读同窗变化的符号是否一致（机会水平 50%）。由于同一录音内的滑窗高度重叠，统计一律先聚合为逐条录音的命中率、再对录音做 bootstrap。另以方差分解量化 token 级轨迹相对“整句一个表情”话轮级基线的 $R^2$ 增益；话轮级基线的面部恒定，该指标按构造为零，天然构成阴性对照。

结果（图 5）：只有 ours 的面部在句内跟随指令。效价大摆动方向命中 87.5%（123 个事件/18 条含事件录音，95% CI $[76.7, 96.0]$，$p < 10^{-4}$），唤醒 69.6%（CI $[56.8, 81.7]$，$p$=0.001）；token 级轨迹相对话轮级基线额外解释 21.8%（效价）与 18.9%（唤醒）的面部方差；逐条录音的循环移位替代数据检验中，效价 16/20、唤醒 11/20 条显著（Fisher 合并 $p < 10^{-23}$）。三条基线在两个维度上均不高于机会水平（效价 37.2%–46.5%、唤醒 53.8%–58.8%，均不显著），$R^2$ 增益不超过 +0.05。

为排除对照不公：四条件共用同一固定 0.5 s 执行加检测滞后（逐条自由搜滞后会让静止/乱序脸拟合噪声占便宜）；面部回读经独立校准——用 40 段已知显示 VA 的静止脸录像拟合线性校准，修正回读器对风格化机器人脸约 5 倍的效价压缩与唤醒串扰，校准集与被测的动态数据完全独立、四条件共用同一映射。

**部署延迟。**表 III给出与上述录制同场同语料、在实机工控机（Intel N100，4 核 CPU，无独立 GPU）上测得的延迟。本文表情通路的逐 token 开销（隐状态投影 → FKCN → EMA）仅 0.7 ms，首次语义脸更新（TTFF，含首 token 前向）不足 1 s；话轮级基线必须等整句生成加分类完毕才能首次按语义改脸，同机 TTFF 为 10–26 s。即在最弱的部署硬件上，流式管线的表情更新粒度与响应速度也比话轮级方案高一个量级以上。

TABLE III

实机部署延迟（Intel N100 工控机，与 C1 同场同语料，均值 ± 标准差，$n$=20）。TTFF：首次语义脸更新时间。

| 方案 | 粒度 | 逐 token (ms) | TTFF (s) |
|---|---|---|---|
| Ours（流式） | token | 0.7±0.2 | 0.96±0.19 |
| Mishra (GPT/Qwen) | 话轮 | — | 10.2±4.3 / 9.9±4.0 |
| Xpress (GPT/Qwen) | 话轮 | — | 9.9±3.8 / 26.5±5.7 |

TABLE IV

人因问卷（$n$=20）。T1：七选一正确率；T2：单选选中率（token / turn / random）。

| 任务 | Ours | 对照 | 说明 |
|---|---|---|---|
| T1 认表情 | 85.5% | 预设 90.5% | 上限对照 |
| T2 句内匹配 | 83.5% | turn 5.0% / random 11.5% | 单选 |

**人因补充。**客观回读确认了物理保真，但未直接回答表情是否可被人识别、句内动态是否更受偏好。为此另做两项无声视频问卷（$n$=20；表 IV）。任务一为七选一认表情：模型被要求以目标情绪回复，被试观看 ours 驱动的脸；另以同机位预设标准表情作可辨识度上限。ours 正确率 85.5%，预设 90.5%（Wilcoxon $p$=0.013）；差距主要来自恐惧–惊讶、悲伤–厌恶等邻近类混淆，预设亦有同类混淆且略轻，说明损失主要来自风格化面部本身而非标签–标签错位。任务二为单选：对含句内转折的句子，在 token、话轮级静脸（turn）与乱序（random）中选更贴情感变化者。ours 被选中 83.5%，random 11.5%，turn 5.0%；全部 20 名被试均为 ours 高于两基线（单侧 Wilcoxon $p<10^{-6}$）。SOTA 具名对照已由上文相机回读承担；人因侧只验证控制粒度，故 turn 取话轮级静脸而非再并列 Mishra/Xpress。综上，人因结果与图 5一致：token 级动态既可被认出，也被偏好为更贴句内变化的执行方式。

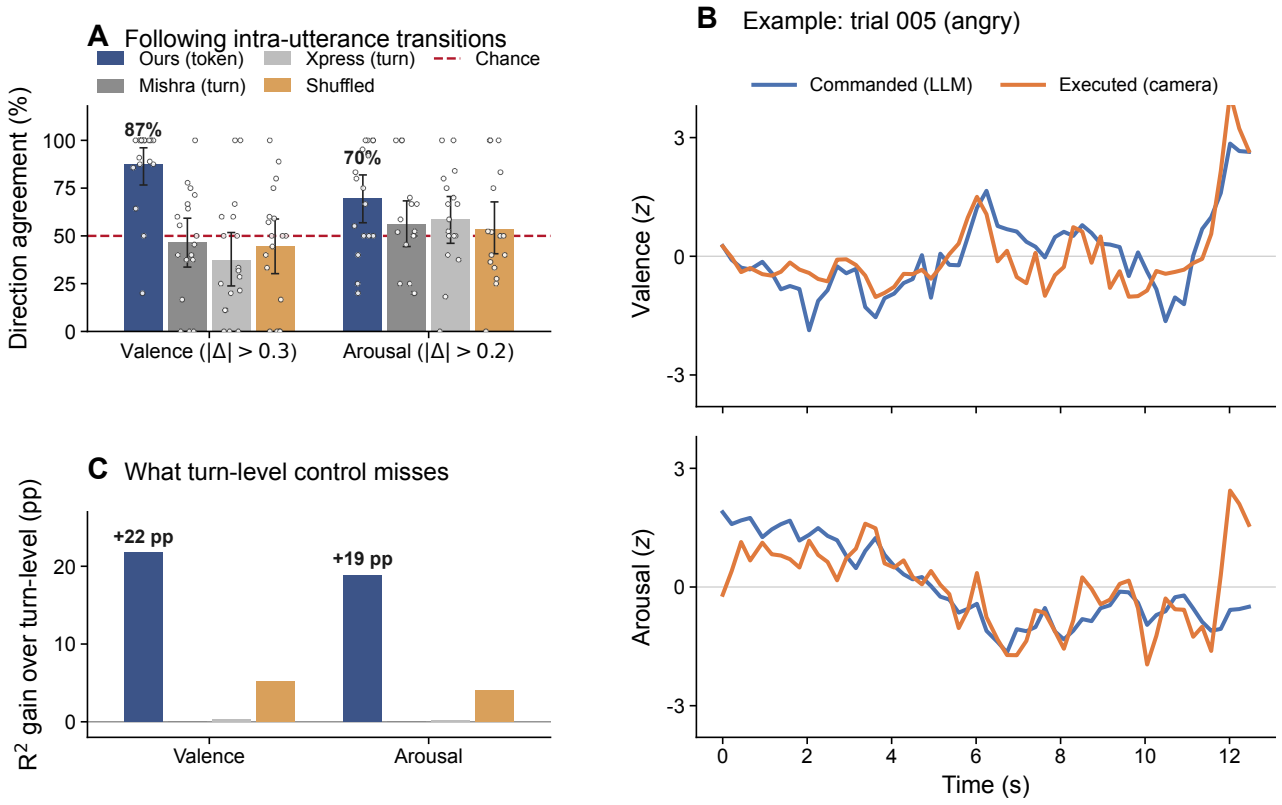



Fig. 5. 逐 token 情感的闭环物理执行：四条件同场对照（$n$=20 段回复）。**(A)** 指令情感转折（2 s 窗）与相机回读的方向一致率：仅 ours 显著高于机会水平（效价 87.5%、唤醒 69.6%），话轮级（Mishra、Xpress）与乱序基线均在机会水平（虚线 50%）。柱为逐条录音命中率均值与 trial 聚类 bootstrap 95% CI，散点为逐条录音命中率。**(B)** 代表性录音 005（愤怒）：固定滞后对齐、$z$ 标准化后的指令（LLM）与执行（相机）效价/唤醒轨迹。**(C)** 相对“整句一个表情”话轮级基线的 $R^2$ 增益：token 级控制额外解释 +22/ + 19 个百分点（效价/唤醒）的面部方差，话轮级基线按构造为零。四条件共用固定 0.5 s 执行加检测滞后；面部回读以静止脸条件独立线性校准。